

פרויקט אנטי-פשינג

מסמך אפיון

- תיחום המערכת: המערכת תהיה אפליקציית ווב שמותאמת למובייל, המאפשרת למשתמש להדביק טקסט של הודעה שחשודה לפשינג. המערכת תבצע ניתוח של ההודעה בעזרת LLM לזיהוי דפוסים ותשווה אותם למאפיינים מוכרים ונפוצים של הודעות פשינג. במקביל, המערכת תסרוק קישורים מתוך ההודעה באמצעות כלי סריקה קיימים (כמו Google Safe Browsing).
- עבור הודעה בטוחה: ה-LLM קובע כי התוכן אינו מניפולטיבי ושלא דומה להודעות פשינג אחרות (אין דחיפה ללחוץ על הקישור או למסור פרטים), והסורק מוודא שהקישור נקי. מוענק ציון בטיחות גבוה והסבר מפורט ("קיימות הודעות קודמות עם השולח, תוכן ההודעה לא תואם לפשינג, קישור נקי" וכו').
- עבור פשינג: המערכת מזהה הפעלת לחץ למסור פרטים או שליחה משרשור שלא קיימות בו הודעות קודמות או שמספיק שהלינק יהיה חשוד ואז מדרגת את ההודעה בציון נמוך ומספקת הסבר מפורט על החשדות ("זוהתה תחושת דחיפות חריגה וקישור המפנה לאתר חשוד"). אם יהיה מספיק זמן אז אוסיף גם אופציה לדיווח על קישורים חשודים ושולחים חשודים.

מטרה ויעדים

- **מטרה**: הקמת כלי הגנה המספק ניתוח מעמיק, ציון מספרי והסבר למשתמשי קצה (ואולי גם אופציה לדיווח אם יהיה זמן) כדי למנוע נפילה להודעות פשינג.
- **יעדים**:
 - פיתוח אפליקציית ווב הכוללת ממשק משתמש פשוט להזנת תוכן של הודעות וקבלת משוב ויזואלי ומילולי ברור על רמת הסיכון של ההודעה.
 - יצירת מנגנון ניתוח מבוסס LLM בעל רמת דיוק גבוהה בזיהוי מניפולציות.
 - שימוש ב-APIs חיצוניים לסריקת לינקים מתוך ההודעה.

לוח זמנים

הלו"ז נבנה בהנחה שיש חודשיים (8 שבועות) עד להגשה ומנסה ככל האפשר להתחשב בבלת"מים כגון שירות מילואים עם תאריך סיום לא ידוע, חלונות זמן לא ידועים מראש במילואים שבהם יש לי זמן לשבת על הפרויקט ובשבוע של מועדי ב' מתישהו במהלך הסמסטר. לכן, הלו"ז הוא יחסית כללי ולא יורד לרמה של תאריכים ספציפיים.

- **שבועות 1+2**: מחקר ולמידה, חקירת כלל הנושאים הרלוונטיים לפרויקט כמו למשל: פסיכולוגיה של הודעות פשינג ודגימה של מספר הודעות כאלו על מנת להבין את המבנה שלהם, מחקר על כלי LLM שאוכל לשלב בפרויקט ושיענו על הדרישות שלי, מחקר על כלי ניתוח לינקים, למידה על בניית אתרים ואיך לשלב את הכלים שלי בתוך האתר.
- **שבועות 3+4**: בניית שלד האתר, מיקום שלו בדומיין (אם צריך) ודיבאגינג.
- **שבוע 5**: בחירת LLM, דיוק שלו על המטרה (לנסות לחדד אותו על תוכן של הודעות פשינג) חיבור ה-API שלו לאתר לקבלת הדירוג וההסבר המפורט.
- **שבוע 6**: חיבור כלי סריקה חיצוניים ובניית המנגנון שמשקלל את כל הנתונים לציון בטיחות סופי והוספת לאתר (וככה העבודה על המערכת בעצם גמורה).
- **שבוע 7**: הרצת בדיקות מול מאגרי הודעות פשינג, דיבאגינג של המערכת וכתובת מסמך התיעוד הסופי.
- **שבוע 8**: שבוע "buffer" בשביל הבלת"מים, חריגות מהלו"ז והוספת אפשרות דיווח.

אתגרים וקשיים

- **בלת"מים:** ניהול הפרויקט תחת שירות מילואים במקביל ללימודים ומבחנים.
- **מחקר מעמיק וממושך:** בחרתי לשלב מספר נושאים שאין לי שום מושג בהם ולכן ייקח לי זמן ללמוד אותם מה שיגרע מסה"כ הזמן שיש לי לפרויקט הזה וייתכן גם מהאיכות שלו (כי זו הפעם הראשונה שאני מתעסק בדברים כאלה).
- **דיוק מודל השפה:** הבטחת עקביות ה-LLM במתן ציונים והסברים לוגיים ללא הזיות ושטויות.
- **טיפול בקישורים מקוצרים:** יהיה גם צורך לפענח כתובות מקוצרות (כמו Bit.ly) לפני שליחתן לסריקה (או אולי עצם השימוש בהם גם מחשיד קצת וכנראה שאפתור את זה תוך כדי המחקר).

חוזקות

- **יצירת ערך מוסף למשתמש:** המערכת מסבירה למשתמש למה ההודעה חשודה, מה שתורם למודעות ולחינוך (Social Engineering).
- **חדשנות טכנולוגית:** שילוב LLM (כי היום הכל AI) כחלק ממערך הגנה הוא צעד המשלב כלים מודרניים בעולם הסייבר.

שם המגיש: לוי ונדרוב